

面向数字员工的 智能任务执行关键技术研究

——主 Agent 决策、多 Agent 编排、记忆与 Skill、权限治理

报告类型	实习课题技术报告
课题名称	面向数字员工的智能任务执行关键技术研究
编写单位	数字员工智能任务执行关键技术研究组
日期	2026 年 8 月

A4 单栏学术版式 · IEEE 风格顺序编码引用

目 录

研究背景	4
研究目标与总体技术框架	4
研究分工与贡献边界	5
1 主 Agent 决策与路由模块.....	7
1.1 问题定义	7
1.2 同类产品与技术路线对比	7
1.3 结构化任务画像	8
1.4 权限感知的 Agent 路由.....	9
1.5 评测集与结果	10
1.6 本章小结	12
2 多 Agent 协同编排与工具选择模块.....	13
2.1 问题定义	13
2.2 同类产品、协议与研究方案对比	13
2.3 候选计划可信化与 TaskGraph.....	14
2.4 控制面与数据面分离	14
2.5 面向众多工具的选择策略	15
2.6 中断、恢复与副作用安全	16
2.7 综合案例与本章小结	17
3 记忆与 Skill 模块.....	19
3.1 问题定义与分层原则	19
3.2 同类产品与前沿研究对比	19
3.3 上下文压缩机制	20
3.4 长期记忆治理	22
3.5 步骤/智能体 Skill 生命周期.....	23
3.6 端到端运行证据与本章小结	24
4 权限治理模块	25
4.1 风险模型与设计原则	25

4.2 同类权限模型与产品对比	25
4.3 S-ABAC 与四道权限闸门.....	26
4.4 审批、委托、Artifact 与副作用治理.....	26
4.5 评测集与量化结果	27
4.6 安全边界与生产化方向	28
4.7 本章小结	28
总体结论	29
附录 A 关键实现与证据索引	29

研究背景

数字员工正在从基于固定规则和流程编排的自动化程序，演进为能够理解自然语言、规划多步骤任务并调用业务工具的智能执行系统。人员信息查询、日程管理、制度检索、差旅处理、会议协同和消息发送等办公任务通常跨越多个业务域，既包含读取、分析和生成等低风险操作，也包含发送、审批和写入等具有真实外部副作用的操作。系统需要在任务语义不完全明确、工具数量持续增长、执行链路跨越多个 Agent 的条件下，保持结果正确、过程可恢复、权限可控制和行为可追溯。

现有单 Agent 或“模型直接选择工具”的实现方式能够快速形成原型，但在复杂任务中存在明显的工程约束。自然语言中的显式意图、隐含前置动作、否定范围、人员实体和步骤依赖难以直接转换为稳定的执行结构；多个 Agent 通过自由对话协作时，控制状态与业务数据容易混合；长对话、跨会话事实和可复用执行经验具有不同生命周期，不能使用同一种存储策略；权限约束如果只存在于 Prompt 中，也无法对越权调用、重复发送和恢复后的副作用重放形成确定性阻断。

本课题面向六类典型办公场景，研究任务理解、协同编排、工具选择、状态管理、权限控制、异常处理和执行闭环，并以不少于 10 个 Agent 和 30 个 MCP 工具为原型规模要求。研究对象不是单一模型能力，而是一套由语义决策、确定性合同、持久化状态和安全治理共同构成的智能任务执行体系。

技术研究围绕四项核心问题展开：如何把自然语言请求转换为可校验的任务画像与路由决策；如何将候选计划转换为可执行、可中断和可恢复的 TaskGraph；如何分别治理当前上下文、跨会话长期记忆和步骤级 Skill；如何在路由、派发、工具调用和结果返回阶段实施一致的权限与副作用控制。最终目标是在 SuperAgent 原型中形成模块边界清晰、接口结构统一、评测结果可复核的数字员工执行框架。

研究目标与总体技术框架

基于上述问题，本课题不把复杂任务执行理解为一块模型调用，而是将其拆为四个职责明确的技术平面：

1. 决策平面：主 Agent 识别用户目标、实体、动作、风险和任务依赖，并在合法候选中选择执行 Agent。
2. 执行平面：TaskGraph 与 Scheduler 组织步骤依赖、并行汇合、工具选择、暂停恢复和结果收敛。
3. 状态平面：上下文压缩、长期记忆、Checkpoint、Artifact 和 Agent Skill 分别保存不同生命周期的信息。

4. 治理平面：S-ABAC、审批、委托、Artifact Guard、Receipt 和审计覆盖从路由到结果的全链路。




图 0-1 总体技术框架

主 Agent 将自然语言转换为受约束的结构化决策；TaskGraph 承载控制依赖，Artifact 承载业务数据依赖；Memory 与 Skill 为后续任务提供状态与经验；治理平面在各关键节点执行确定性检查。

研究分工与贡献边界

表 1 研究分工与贡献边界

模块	主要研究内容	主要成果证据
主 Agent 决策与路由	意图目录、TaskProfile、澄清、AgentCard、权限感知路由、RoutingDecision	33 条意图评测、主 Agent 决策台、结构与合同测试
多 Agent 协同编排与工具选择	候选计划可信化、TaskGraph、Scheduler、Artifact、Tool Resolver、暂停恢复	48 工具评估、年假案例、恢复对照实验、MCP 原型
记忆与 Skill	上下文压缩、长期记忆治理、步骤/智能体 Skill 晋升与复用	三档上下文压力、64 条 Memory、36 条 Skill、17 条完整链路
权限治理	S-ABAC、四道 PEP、三态审批、Artifact Guard、Receipt、审计	21 条治理矩阵、12 条 API、105 项核心测试、前端治理台

四个模块共享统一的 `task_id`、`trace_id`、用户身份、Agent/Tool 契约和数据范围。报告中的“已实现”仅指专题材料和代码证据能够直接支持的原型能力；“设计方案”与“后续工作”不计入实测结果。

1 主 Agent 决策与路由模块

1.1 问题定义

复杂办公指令往往同时包含显式动作、隐含前置动作、否定、条件、人员和时间实体。例如“查询张三的收入情况，生成证明，但先不要发送”至少包含人员查询、薪资读取、文档生成和被否定的外发动作。如果将原始文本直接交给 Planner，一次模型调用需要同时完成意图分类、实体抽取、依赖构造、Agent 选择和计划生成，任何局部错误都会向后传播，而且难以单独评测和审计。

本模块将主 Agent 的任务定义为：把自然语言转换为可校验的任务画像，在权限和能力边界内召回 Agent，并输出可解释的路由决策。其成功标准不只是“选对一个 Agent”，而是保证任务边界、执行动作、数据范围、依赖关系和风险属性能够被下游确定性组件消费。

1.2 同类产品与技术路线对比

OpenAI Agents SDK 将多 Agent 组织分为 manager-style 的“Agents as tools”和将控制权交给专业 Agent 的 handoff，并通过代码编排增强速度、成本和性能的可预测性。AutoGen 提供 RoundRobin、SelectorGroupChat、Swarm 等对话式团队模式，适合开放式协作，但简单任务仍应控制 Agent 数量与交互复杂度。LangGraph 以显式图和状态组织路由、并行、持久化和人工中断。这些框架提供通用编排原语，但企业数字员工仍需自行补充业务意图目录、组织权限、数据范围和动作风险。

表 2 主 Agent 同类产品与技术路线对比

方案/产品	决策方式	优势	对本课题的不足	本项目取舍
纯规则分类	关键词、正则、词典	稳定、低时延、可解释、可离线	同义表达与隐含意图覆盖有限	作为确定性基线和降级路径
纯 LLM/Planner	模型直接输出意图、Agent 或计划	语义泛化强、原型开发快	输出漂移，难形成安全边界	只生成候选，不直接授权执行
OpenAI Agents SDK	manager、agent-as-tool 或 handoff	原语轻量，支持工具、guardrail、tracing	业务权限和任务级数据范围需应用层实现	采用 manager 保持最终控制的思想
AutoGen	对话式 team、selector、swarm	协作灵活，适合开放任务	共享消息容易混合控制与业务数据	不采用部门 Agent 自由互调作为主链
LangGraph	Router + StateGraph	执行关系显式，可持久化与恢复	图来源仍需业务契约校验	采用显式图执行思想
SuperAgent	TaskProfile + AgentCard	业务语义、能力、风险和权限统一进入可审计	需要维护意图目录和能	本项目采用

方案/产品	决策方式	优势	对本课题的不足	本项目取舍
	+ 权限硬过滤 + 评分	决策	力卡	

与同类框架相比，本项目的重点不是新增一种通用对话模式，而是将“模型可以考虑哪些 Agent”先约束为权限与能力合法集合，再进行语义评分。权限不是总分中的一个权重，不能被更高的语义相似度抵消。

1.3 结构化任务画像

主 Agent 首先通过 Intent Catalog 将业务意图、动作、能力、风险和数据范围映射到统一枚举。规则识别器负责明确动作、人员、时间、文档类型、否定范围和高确定性实体；可选语义识别器补充同义表达、隐含前置动作和复杂条件。两路结果经融合、去重和冲突检测后进入 Pydantic Schema，形成 TaskProfile。

TaskProfile 至少包含主意图、子意图、实体、动作、任务类型、数据范围、风险、不可逆标志、缺失字段、置信度和子任务依赖。每个意图保留 explicit 或 inferred 来源、证据文本和文本范围。被否定动作保留用于审计但不进入可执行子任务；条件动作被转换为显式依赖和条件门。关键对象缺失时，ClarificationAnalyzer 生成具体问题，而不是让低置信度结果继续执行。




图 1-1 主 Agent 结构化决策流程

1.4 权限感知的 Agent 路由

每个执行 Agent 注册统一 AgentCard 和 AgentContract。能力卡描述部门、支持意图、能力、动作、可接受数据范围、风险上限、状态、工具范围和版本；契约进一步定义输入输出名称、Schema、基数和必需字段。

路由先执行硬过滤：用户是否有权访问该 Agent、Agent 是否在线、是否支持目标动作、是否接受任务数据范围、风险是否超过上限。只有合法候选进入软评分。当前评分为：

$$\text{RouteScore} = 0.35S_{\{\text{intent}\}} + 0.25S_{\{\text{capability}\}} + 0.15S_{\{\text{scenario}\}} + 0.10S_{\{\text{scope}\}} + 0.10S_{\{\text{history}\}} + 0.05S_{\{\text{availability}\}}$$

RoutingDecision 保存选中 Agent、Top-K 候选、各分项得分、被排除 Agent、原因码和 trace_id。当关键字段缺失时返回 CLARIFY；无合法候选时返回 REJECT 或 NO_CAPABLE_AGENT，不能回退到一个权限更宽的通用 Agent。

主 Agent 决策台：任务画像、候选过滤与可解释路由

(a) 意图详情与任务边界

主 Agent 决策台
选择对话后需要任务画像、候选 Agent 与路由依据。 (已分派: 100%)

对话窗口: 查询员工张三的工资 - 06/11 08:53 决策轮次: 第 1 轮: 查询员工张三的工资 - 06/11 08:47

当前员工张三的工资 - 第 1 轮: 06/11 08:47 - 当前员工张三的工资

主意图 employee_informat ion_query	复合任务 是	任务类型 HR	动作 read	风险 LOW
期望能力 HR	缺失字段 无	子任务数 2	新置信度 92%	

推荐: RemoteHRAssistantAgent - 100%

意图详情: 意图详情 2 | 实体与数据 1 | 子任务 2 | Agent 候选 1 | 决策依据 6

意图需求与上下文: 查询员工张三的工资
本局和环需求

多意图识别 / 子意图: employee_informaton_query - 82% | salary_query - 99%

任务边界 / 文本分块: 1. 查询张三的工资
segment: 1, 0-9

(b) 实体识别与数据范围

主 Agent 决策台
选择对话后需要任务画像、候选 Agent 与路由依据。 (已分派: 100%)

对话窗口: 查询员工张三的工资 - 06/11 08:53 决策轮次: 第 1 轮: 查询员工张三的工资 - 06/11 08:47

当前员工张三的工资 - 第 1 轮: 06/11 08:47 - 当前员工张三的工资

主意图 employee_informat ion_query	复合任务 是	任务类型 HR	动作 read	风险 LOW
期望能力 HR	缺失字段 无	子任务数 2	新置信度 92%	

推荐: RemoteHRAssistantAgent - 100%

意图详情 2 | 实体与数据 5 | 子任务 2 | Agent 候选 1 | 决策依据 6

实体与数据: 实体识别: employee_name: 张三 | business_object: 工资 | people: 张三

数据范围: employee_basic_profile | employee_salary

(c) 子任务拆解与依赖

主 Agent 决策台
选择对话后需要任务画像、候选 Agent 与路由依据。 (已分派: 100%)

对话窗口: 查询员工张三的工资 - 06/11 08:53 决策轮次: 第 1 轮: 查询员工张三的工资 - 06/11 08:47

当前员工张三的工资 - 第 1 轮: 06/11 08:47 - 当前员工张三的工资

主意图 employee_informat ion_query	复合任务 是	任务类型 HR	动作 read	风险 LOW
期望能力 HR	缺失字段 无	子任务数 2	新置信度 92%	

推荐: RemoteHRAssistantAgent - 100%

意图详情 2 | 实体与数据 5 | 子任务 2 | Agent 候选 1 | 决策依据 6

子任务拆解: 子任务拆解: 1. 查询张三工资基本信息
employee_informaton_query - HR - 依赖: -
2. 查询张三薪资或收入信息
salary_query - HR - 依赖: subtask_1

(d) Agent 候选与排除原因

主 Agent 决策台
选择对话后需要任务画像、候选 Agent 与路由依据。 (已分派: 100%)

对话窗口: 查询员工张三的工资 - 06/11 08:53 决策轮次: 第 1 轮: 查询员工张三的工资 - 06/11 08:47

当前员工张三的工资 - 第 1 轮: 06/11 08:47 - 当前员工张三的工资

主意图 employee_informat ion_query	复合任务 是	任务类型 HR	动作 read	风险 LOW
期望能力 HR	缺失字段 无	子任务数 2	新置信度 92%	

推荐: RemoteHRAssistantAgent - 100%

意图详情 2 | 实体与数据 5 | 子任务 2 | Agent 候选 1 | 决策依据 6

Agent 候选与排除原因: 合法候选与得分: RemoteHRAssistantAgent - 100%
被排除 Agent 与原因: coder (权限不足: 当前用户无权限访问该 Agent), browser (权限不足: 当前用户无权限访问该 Agent), RemoteWeatherAgent (权限不足: 当前用户无权限访问该 Agent), RemoteUnicornSelectorAgent (权限不足: 当前用户无权限访问该 Agent), RemoteBusinessRiskAgent (权限不足: 当前用户无权限访问该 Agent), RemoteReportAgent (权限不足: 当前用户无权限访问该 Agent), RemoteEmailDispatchAgent (权限不足: 当前用户无权限访问该 Agent), RemoteScheduleAgent (权限不足: 当前用户无权限访问该 Agent)

排除 5 个排除项

(e) 路由决策依据

主 Agent 决策台
选择对话后需要任务画像、候选 Agent 与路由依据。 (已分派: 100%)

对话窗口: 查询员工张三的工资 - 06/11 08:53 决策轮次: 第 1 轮: 查询员工张三的工资 - 06/11 08:47

当前员工张三的工资 - 第 1 轮: 06/11 08:47 - 当前员工张三的工资

主意图 employee_informat ion_query	复合任务 是	任务类型 HR	动作 read	风险 LOW
期望能力 HR	缺失字段 无	子任务数 2	新置信度 92%	

推荐: RemoteHRAssistantAgent - 100%

意图详情 2 | 实体与数据 5 | 子任务 2 | Agent 候选 1 | 决策依据 6

路由决策: 路由决策: 已分派 路由置信度: 100% 输出路由: 路由环

路由决策依据: 路由决策依据: rule 1, rule=semantic 1
• 可识别意图 2 个: 意图 1, 意图 2
• 生成 2 个子任务, 其中条件任务 0 个
• 抽取实体字段: employee_name, business_object, people
• 存在 1 个谓词以定义

图 1-2 主 Agent 决策台多视图成果展示

1.5 评测集与结果

意图评测集包含 33 条固定用例, 覆盖单意图、复合任务、隐式依赖、同义表达、条件任务、缺失字段、否定动作、咨询误触发和关键词边界。严格整例只有主意图、子意图、实体、动作、依赖、风险、缺失字段、澄清和置信度区间全部满足标注才通过。

表 3 主 Agent 意图画像评测结果

指标	结果	解释
严格整例通过率	60.61%（20/33）	任一已标注字段或置信度区间错误即失败
主意图准确率	93.94%	顶层业务域识别较稳定
子意图 Precision / Recall	100.00% / 98.48%	几乎不多执行，少量隐含意图漏召回
实体字段准确率	96.46%	人员、收件人、文档类型总体稳定
依赖完全准确率	92.31%	复合任务大部分执行顺序正确
澄清判定准确率	95.60%	澄清触发判断总体稳定，少量边界表达仍需优化
否定动作误执行率	0.00%	标注的否定动作未进入执行子任务




图 1-3 意图画像关键指标

关键字段指标较高而严格整例通过率较低并不矛盾。严格判定会把置信度越界、多一个 missing_field 或少一条依赖均判为整例失败。结果表明当前规则链路已能支撑边界明确的办公任务，澄清判定准确率达到 95.60%；当前误差主要集中在知识制度与报告生成的关键词边界和弱同义表达，少量模糊边界样本仍需补充。后续应在固定模型、Prompt 和温度条件下补充 rule、semantic、hybrid 三组对照，而不能直接宣称混合模式必然优于规则模式。

1.6 本章小结

主 Agent 模块将“分类一句话”升级为“生成可执行、可路由、可审计的任务画像”。其相对通用框架的主要价值，是在模型决策前引入权限与能力硬边界，在模型决策后保留结构校验和原因码，从而为 TaskGraph 规划、权限治理和中断恢复提供统一语义入口。

2 多 Agent 协同编排与工具选择模块

2.1 问题定义

复杂任务需要多个 Agent 按数据依赖和执行依赖共同完成。模型生成的自然语言计划不能直接证明 Agent 存在、能力合法、输入输出兼容或依赖无环；多个 Agent 若只通过消息对话传递结果，又会把过程通信、业务数据、执行状态和错误信息混为一体。当 MCP Server 数量和工具数量增加后，把全部工具描述直接放入 Prompt 还会造成上下文膨胀、工具误选和 API 幻觉。

本模块研究四个问题：如何将候选计划变成可信任务图；如何组织多 Agent 并行与汇合；如何从大量 MCP 工具中缩小候选；如何在暂停、失败和进程重启后保存进度并避免副作用重复发生。

2.2 同类产品、协议与研究方案对比

ReAct 通过交替推理与行动动态调整步骤，适合开放环境，但完整路径在运行中逐步形成。Plan-and-Solve 先分解再执行，可减少漏步骤，但候选计划仍来自模型。AutoGen 强调基于消息的多 Agent 团队；LangGraph 通过图状态和 Checkpoint 提供并行、人工中断与故障恢复；A2A 使用 Agent Card、Task、Message 和 Artifact 描述跨 Agent 互操作。本项目结合这些机制，采用“LLM 候选规划 + 确定性校验 + TaskGraph 执行”，同时区分控制面与数据面。

表 4 多 Agent 编排方案对比

方案/产品	主要机制	优势	局限	本项目吸收点
ReAct	推理与动作交替	动态适应环境反馈	路径难提前整体校验	保留运行时反馈，不让其绕过任务图
Plan-and-Solve	先规划后求解	降低漏步骤	计划本身仍可能幻觉	Planner 只产生候选计划
AutoGen	对话式多 Agent team	协作模式灵活	消息、状态和业务结果易混合	专业 Agent 分工
LangGraph	图 workflow、Checkpoint、Interrupt	依赖显式、可恢复	业务契约需自行补充	TaskGraph、Scheduler、恢复
A2A	Agent Card、Task、Artifact	标准化 Agent 互操作	不负责组织内部权限与工具选择	AgentCard 与 Artifact 分层
SuperAgent	合同校验 TaskGraph + Artifact 数据面	可校验、可调度、可审计	当前为单机研究原型	本项目采用

2.3 候选计划可信化与 TaskGraph

Planner 根据 TaskProfile 和合法 Agent 候选生成步骤、依赖和期望输出，但不能直接决定执行。候选计划依次经过归一化、任务覆盖校验、Agent Contract 校验、输入输出 Schema 校验、数据依赖校验和 DAG 校验，最终转换为 TaskGraph。Planner 不能虚构不存在的 Agent、工具或 Schema，也不能扩大 TaskProfile 中的动作和数据边界。

用户任务 → TaskProfile → Planner 候选计划 → 计划归一化
 → 任务覆盖校验 → Agent Contract / Schema 校验
 → 数据依赖与 DAG 校验 → TaskGraph → Scheduler


TaskGraph 描述控制依赖，Scheduler 根据已完成节点计算 READY 集合，组织并行执行、资源冲突控制、失败隔离和状态推进。每个步骤返回标准化 StepResult，避免把 Agent 自由文本误当作成功状态。

2.4 控制面与数据面分离

本项目将“何时执行”与“传递什么业务结果”分开管理：

- 控制面：TaskGraph → Scheduler → StepResult，负责依赖、并行、状态与失败。
- 数据面：Agent → Artifact → ArtifactRef → ArtifactResolver → Agent，负责结构化业务结果、所有权、敏感级别、校验和数据血缘。

Agent 成功后输出被规范化为 Artifact，下游步骤只持有 ArtifactRef，不直接依赖上游 Agent 的内部运行状态。TaskGraph 与 Artifact 通过 StepResult.outputs 建立关联。该设计区分 Message 与 Artifact，并进一步把所有权、敏感级别和权限校验纳入本地数据面。



TaskGraph 描述执行依赖；Artifact 描述数据依赖

图 2-1 多 Agent 控制面与数据面

2.5 面向众多工具的选择策略

Toolformer 研究模型何时、如何调用工具；Gorilla 通过 API 文档检索降低 API 调用幻觉；ToolLLM 面向大规模真实 API 构建检索、训练和评测框架；MCP 统一了工具发现、描述和调用协议，但工具目录扩大后的候选筛选仍由上层系统负责。

表 5 工具选择技术路线对比

方案	解决重点	对本课题的启示	不直接采用的原因
Toolformer	模型学习工具调用时机与参数	工具使用是独立能力	需要模型训练，原型成本高
Gorilla	API 文档检索与调用准确性	大工具集需要先检索	目标 API 分布与办公 MCP 不同
ToolLLM	大规模 API 检索、训练和评测	先压缩候选再决策	训练与数据构造超出本阶段范围
MCP	统一 tools/list、Schema 和 tools/call	提供动态发现与标准接口	协议本身不负责业务候选排序
SuperAgent Tool Resolver	元数据过滤、可解释评分、Top-K、ABSTAIN	低成本、可审计、适合受控办公域	当前主要处于 audit 模式

原型通过 tools/list 获取工具元数据，形成如下分层选择链：

```
ToolRegistry
→ MCP Server / Scenario 过滤
→ Operation 过滤
→ Agent 授权过滤
→ Input Schema 与已知参数校验
→ 名称、别名、意图和描述评分
→ Top-K
→ Tool 或 ABSTAIN
```

不存在合理候选时返回 ABSTAIN，而不是强迫模型从错误工具中选择。当前固定评估集包含 30 个 Office MCP 工具和 18 个 Excel MCP 工具，共 48 个工具；同时原型注册 14 个远程 Agent，满足任务书不少于 10 个 Agent 和 30 个 MCP 工具的结构性要求。

表 6 Tool Resolver 固定评估结果

指标	结果	测试条件
平均过滤前候选数	48	固定 MCP 工具集合
平均过滤后候选数	2.17	确定性过滤与评分后

指标	结果	测试条件
Tool Top-1 / Top-3	100% / 100%	固定评估集
参数 / Schema 有效率	100%	固定评估集
不存在工具幻觉率	0%	固定评估集
平均选择耗时	约 1.51 ms	本地评估环境




图 2-2 Tool Resolver 候选压缩效果

上述结果只验证当前固定工具集上的机制可行性。由于 Tool Resolver 主要以审计模式记录推荐并与 Executor 实际选择对照，不能表述为已全面强制替换 Executor 的工具集合，也不能据此推断开放工具环境中的泛化准确率。

2.6 中断、恢复与副作用安全

LangGraph Persistence 通过每一步 Checkpoint 支持人工中断、跨轮记忆和故障恢复；Temporal 通过持久化运行状态支持 workflow 跨进程失败恢复和重放。本项目在研究原型中实现 Scheduler 安全点协作式暂停：

RUNNING → PAUSE_REQUESTED → PAUSED → RUNNING

收到暂停请求后，不立即强杀正在运行的远程 Agent，而是等待当前并发批次完成，持久化关键 Artifact 与 Checkpoint，在下一批步骤启动前进入 PAUSED。恢复时读取 completed_steps、StepResult 和 ArtifactRef，已经成功完成的节点不重复执行。

对具有外部副作用的发送、写入和会议创建，Checkpoint 本身不足以解决“外部已成功、本地尚未记录”窗口。系统为此引入 Idempotency Key、原子 Receipt 和

NEEDS_RECONCILIATION。已确认成功的副作用恢复后直接复用；结果不确定时进入人工对账，不盲目重试。

失败恢复离线对照实验在固定随机种子、Stub Router/Executor 和人工故障注入条件下，每种策略运行 500 次：

表 7 失败恢复离线对照实验

策略	任务闭环率	首次失败后恢复成功率	重复副作用	治理违规
B0: 无自动恢复	12.4%	0%	0	0
B1: 同 Agent 有界重试	27.2%	16.9%	0	0
B2: 重试后等价 Agent 改派	40.0%	31.5%	0	0




图 2-3 失败恢复策略对照

该实验用于比较恢复机制，不代表生产成功率。自动重试与改派目前主要限于只读步骤；写入与发送保持保守策略。暂停属于 Scheduler 安全点协作式暂停，而不是对远程 Agent 的即时抢占。

2.7 综合案例与本章小结

员工年假查询案例将用户任务拆为 HR Agent + Knowledge Agent → Report Agent。前两路并行产生员工信息和制度信息 Artifact，Report Agent 在两路均完成后通过 ArtifactRef 读取数据并生成 Markdown。扩展链路可加入历史请假、审批和模拟邮件，形

成 HR + Knowledge → Office → Report → Approval → Email。审批拒绝时此前成功的业务成果仍保留，重复 Approval 或 Resume 不产生第二次模拟发送。

本模块的核心贡献是将模型生成的开放式候选计划转化为可校验、可调度、可协作、可恢复的执行过程，并针对众多工具采用“先过滤、后评分、可弃权”的分层选择策略。

3 记忆与 Skill 模块

3.1 问题定义与分层原则

数字员工的“记住”至少包含三种不同问题：当前长对话如何控制 Token 并保持执行连续性；跨会话偏好、事实和约束如何治理；同一 Agent 的稳定执行方法如何跨任务复用。如果将三者都存入一张向量表，摘要、用户事实和程序性经验会共享不合适的写入、更新、召回和失效规则。

本项目因此建立三个独立状态通道：

5. 上下文压缩：面向当前会话历史，目标是释放 Token，同时保留最近完整轮次和未完成运行状态。
6. 长期记忆：面向跨会话稳定信息，强调固定标签、来源、用户/项目范围、冲突更新和时间衰减。
7. 步骤/智能体 Skill：面向跨任务程序性经验，强调成功证据、Agent/Tool/Schema 契约和副作用边界。




图 3-1 数字员工的真实问题与本项目方案

3.2 同类产品与前沿研究对比

OpenAI Agents SDK Sessions 提供会话级历史持久化，适合多轮对话，但其职责主要是保存会话上下文。LangGraph 将线程内短期状态放入 Checkpointer，并通过 Store 保存跨线程长期记忆，同时区分 semantic、episodic 和 procedural memory。MemGPT 以操作系统分层存储类比实现虚拟上下文管理；Mem0 动态抽取、整合和检索显著信息，并评估准确率、时延和 Token 成本；Voyager 通过可执行代码 Skill Library 保存可组合技能。

表 8 记忆与 Skill 同类产品对比

产品/研究	核心机制	优势	对银行办公场景的不足	本项目对应设计
OpenAI Sessions	会话历史持久化	接入简单，自动维护多轮上下文	不直接处理跨会话事实治理和步骤 Skill	当前会话状态独立管理
LangGraph Memory	Checkpoint + Store	区分线程状态与跨线程存储	具体标签、冲突和权限策略由应用定义	短期/长期状态分层
MemGPT	分层虚拟上下文	面向超长上下文的动态换入换出	企业来源审计与权限需扩展	压缩后重组执行状态
Mem0	动态抽取、整合、检索	面向生产长期记忆与基准评测	语义检索链和部署成本更高	当前采用固定办公标签的轻量方案
Voyager	可执行 Skill Library	技能可解释、可组合、可持续积累	面向 Minecraft，非企业契约与权限	步骤/Agent Skill + 契约门禁
SuperAgent	压缩、长期记忆、Skill 三通道	生命周期清晰，来源和治理边界完整	语义检索和在线 LLM 评测不足	本项目采用

本项目的先进性在于组合和治理：不仅存储内容，还规定什么时机写、保留何种来源、如何处理冲突、哪些主体可以召回、何时失效，以及程序性经验在何种契约下可以复用。

3.3 上下文压缩机制

系统对旧对话进行结构化压缩，而不是固定保留大量历史消息。压缩后最多保留最近两个完整对话轮次；执行中的 Plan、TaskGraph 和 Artifact 不进入普通摘要，任务结束后才作为历史处理；System Prompt 每轮根据最新工具、权限和配置重新构造，不参与压缩。

LLM 摘要失败时启用确定性兜底，并以“压缩后 Token 必须小于压缩前”为硬门禁。压缩后系统重新组装结构化摘要、最近轮次、未完成 Plan、TaskGraph 和 Artifact，使摘要服务于继续执行而不是只生成归档文本。

表 9 上下文压缩评测结果

上下文配置	压缩代数	压缩前 Token	压缩后 Token	降幅
8K	4	4,426	3,460	21.8%
16K	4	6,939	6,262	9.8%
32K	1	11,905	6,137	48.5%




图 3-2 不同上下文规模下的 Token 变化

三档均保留最近两个完整的“用户消息—Assistant 回复”轮次，并检查员工姓名“王强”、累计工龄“20 年”、年假“15 天”和“禁止外部操作”四项预置事实，每档均为 4/4。压缩后分别继续执行一条年假政策分析工作流，每条工作流包含员工信息、政策检索和报告生成 3 个步骤，并产生 employee.info、policy.info 和 report.markdown 3 个结构化 Artifact。三条工作流合计完成 9/9 个步骤、生成 9/9 个 Artifact，最终报告事实命中 9/9，禁止的发送、审批或外部写入为 0 次。




图 3-3 压缩后的任务接续能力

该结果说明压缩后的结构化状态能够作为主 Agent 下一轮的恢复上下文继续工作，而不仅是生成一份归档摘要。

3.4 长期记忆治理

长期记忆使用固定办公标签，覆盖语言、报告风格、文档格式、审批、隐私、身份、组织和周期任务等信息。提取在完整用户回合结束后由后台任务执行，避免阻塞用户响应。每条记忆保存来源消息、来源会话、用户/项目范围、置信度和生命周期状态。

重复内容强化原记录；冲突内容保留旧版本并激活新版本；旧记忆随时间衰减但不删除来源；低置信度和过期内容不进入有效召回。长期记忆只注入主 Agent，远端 Agent 只获得当前 Plan 所需的最小信息，降低跨 Agent 隐私扩散。

长期记忆专项包含偏好记忆、办公约束、稳定事实和项目范围四类任务，每类包含常规与对抗两档难度，每档 8 条，共 $4 \times 2 \times 8 = 64$ 条确定性模块案例。四类任务均为 16/16 与预期一致，总体为 64/64。聚合召回结果为 TP=44、FP=0、FN=0，Precision、Recall 和 F1 均为 1.0；来源消息与来源会话覆盖 40/40 条需要来源证明的正向记录；重复合并 4/4，冲突更新 4/4，跨用户与范围隔离 8/8，陈旧记忆衰减 4/4，低置信度拒绝 4/4，过期拒绝 4/4，有效版本唯一性 4/4。

时间衰减使用距上次强化 0、30、90 和 180 天的样本，召回权重依次为 0.855、0.679、0.428 和 0.214。衰减只降低召回权重，不删除来源事实，仍可通过来源会话完成审计和重新强化。




图 3-4 长期记忆的时间衰减

“冲突更新”表示同一记忆标签出现新值时，新值成为当前生效内容并参与后续召回；旧值不再注入 Agent 上下文，只保留来源消息、更新时间和替换关系用于审计与追溯，而不是让新旧冲突值同时生效。

这些结果验证的是 MemoryStore、标签召回器和治理状态机，不代表 LLM 能从任意自然语言中 100% 正确提取长期记忆。在线评测仍需分别测量“是否应该记、标签是否正确、值是否正确、来源是否正确”。

3.5 步骤/智能体 Skill 生命周期

本项目不再沉淀整条 Workflow Skill，而是以 Step/Agent 为粒度保存某个 Agent 完成某类步骤的可靠方法。Planner 仍负责当前任务需要哪些步骤和依赖，Skill 只回答“这个步骤如何稳定执行”。

Skill 先由反思判断是否属于常规可复用流程，再要求至少两次独立成功证据晋升。晋升与复用均校验 Agent、工具、输入输出、Schema、用户、数据范围和副作用等级。命中后只在对应 Plan 步骤附加 Skill 引用和执行指导，不跳过 Planner。

36 条 Skill 边界评测覆盖员工信息、薪资、制度、报告、日程和邮件六类步骤族。首次证据建档、两次独立证据晋升、实体变化复用、契约与 Schema 漂移拒绝、用户/数据范围隔离、反思或业务身份门禁六类能力维度均为 6/6，总体为 36/36。

实体变化复用检查员工姓名、制度名称、报告主题等具体值变化，但 Agent、工具链和输入输出契约保持不变时，系统能否识别为同类步骤。五个低风险步骤均正确复用；邮件发送属于高风险副作用，按预期保持禁止自动复用，因此该维度六条案例也全部符合设计边界。




图 3-5 Skill 能力判定结果

Skill 记录数、证据数和复用次数只用于运行审计，不作为核心能力指标。核心是可复用流程能否命中，以及契约、身份或风险不兼容时能否拒绝。当前反思使用确定性测试替身，尚不能据此宣称在线模型对“常规可复用流程”的判断准确率。

3.6 端到端运行证据与本章小结

独立于模块专项评测，项目已有 17 条本地完整链路运行，17/17 均达到各自预期终态：

- 上下文压力工作流 3/3：8K、16K、32K 三档均完成真实压缩并成功接续，合计完成 9/9 个步骤、生成 9/9 个 Artifact、恢复 9/9 项报告事实，禁止副作用为 0 次。
- 失败隔离工作流 3/3：政策未找到、知识服务 HTTP 异常和日期字段异常均进入预期安全终态，依赖失败后没有继续产生下游外部副作用。
- 审批与副作用策略工作流 8/8：4 次批准均为 SUCCEEDED 并各写入 1 封 Mock 邮件，4 次拒绝均为 FAILED 且写入 0 封，审批决策与实际副作用一致。
- Skill 生命周期工作流 3/3：首次执行形成候选证据、第二次相似执行完成晋升、第三次执行验证复用，三次均为 SUCCEEDED，并分别生成员工信息、政策信息和报告三个结构化 Artifact。

17 条端到端运行验证模块间连接关系，64 条长期记忆和 36 条 Skill 专项则验证不同输入关系与风险边界下的模块判定，二者分开统计。记忆与 Skill 模块由此使“继续当前任务”“跨会话记住用户”和“复用稳定步骤”分别拥有合适的证据、范围和失效规则。当前机制完整、可复核，但多信号语义记忆、时间知识图谱和真实 LLM extraction/reflection 仍是下一阶段重点。

4 权限治理模块

4.1 风险模型与设计原则

数字员工不仅读取信息，还可能查询工资、生成证明、创建会议、写入请假和发送邮件。模型可能因提示注入、语义误判、工具幻觉或上下文缺失选择越权动作，Agentic Application 的常见风险也包括工具滥用、身份冒用和权限滥用。权限若只写入 System Prompt，只能影响模型行为，不能构成不可绕过的安全边界。

本项目遵循四项原则：权限硬约束先于语义评分；每次 Agent、工具和 Artifact 访问均按请求重新评估；未知主体、资源、动作或关键存储异常时失败关闭；高风险操作需要绑定具体任务和参数的一次性人工审批。

4.2 同类权限模型与产品对比

ABAC 根据主体、对象、操作和环境属性作出授权决策，比单纯角色更适合动态办公任务；零信任架构强调按请求评估和最小权限。OPA 将策略决策与业务执行解耦，作为 PDP 接收结构化输入，并由应用侧 PEP 强制执行。Cedar 使用 principal、action、resource、context 描述授权请求，并支持 permit/forbid 与 Schema。OpenAI Agents SDK Guardrails 提供输入、输出和工具级校验，但组织角色、数据范围和任务委托仍需业务系统实现。

表 10 权限模型与产品对比

方案/产品	主要依据	优势	局限	本项目定位
ACL	用户—资源列表	简单直接	用户、Agent、工具增长后难维护	不单独采用
RBAC	角色	符合组织结构	难表达业务目的、数据范围和动作风险	作为 Subject 属性
ABAC	主体、对象、操作、环境属性	细粒度、动态	属性与策略治理成本高	基础模型
ReBAC	所有者、成员、关系	适合 Artifact 所有权与共享	需要关系图基础设施	局部用于所有权控制
OPA	Rego + PDP/PEP	策略与业务解耦，部署成熟	增加服务与策略语言成本	生产迁移候选
Cedar	principal/action/resource/context	Schema 清晰、permit/forbid 可分析	需引入新策略栈	生产迁移候选
OpenAI Guardrails	输入、输出、工具校验	与 Agent/Tool 调用结合紧密	不等同于企业授权模型	通用安全扩展点参考

方案/产品	主要依据	优势	局限	本项目定位
SuperAgent S-ABAC	Subject/Object/Scenario/Action	贴合任务目的、风险和 数据范围	当前策略仍为本地配置	本项目采用

4.3 S-ABAC 与四道权限闸门

S-ABAC 将 Scenario 作为一等维度：

- Subject: 原始用户、执行 Agent、部门、岗位、信任等级和委托范围。
- Object: 目标 Agent、工具或 Artifact 的归属、敏感度、数据范围和安全属性。
- Scenario: 业务目的、任务类型、风险、时间、网络区域、审批状态和数据范围。
- Action: read、write、send、delete、approve 等具体操作。

PolicyEngine 返回 ALLOW、DENY 或 REVIEW_REQUIRED。人工审批只能放行 REVIEW_REQUIRED，不能把 DENY 提升为允许。原型在四个位置部署 PEP：

8. 路由前：无权 Agent 不进入候选集合。
9. 派发前：重新校验目标 Agent、动作、数据域和风险。
10. 工具前：逐次校验工具归属、委托、参数、场景和审批状态。
11. 结果前：Artifact Guard 校验所有者、敏感级别、数据范围和校验和。




图 4-1 四道权限治理闸门

4.4 审批、委托、Artifact 与副作用治理

任务级 DelegationGrant 区分 delegation 与 impersonation，同时绑定原始用户和执行 Agent，并限制 task/trace、动作、工具、数据范围、过期时间、调用次数和 approval_id。主 Agent 不以系统管理员身份替用户执行，也不把自身权限无条件传给下游 Agent。

敏感业务结果不以原始字典在步骤间传递，而是通过 ArtifactRef 访问。Artifact 携带 owner、producer、sensitivity、checksum 和 derived_from；Checkpoint 只保存脱敏引用与校验和，审计不记录 payload 或 URI。跨用户读取必须由可信来源显式授权。

邮件和会议等副作用由 task_id + step_id + 标准化输入 生成幂等键。原子 Receipt 记录 STARTED/SUCCEEDED 和外部操作号；恢复时已成功操作不重复执行，状态不确定则转人工核对。SHA-256 校验和只能发现意外损坏和简单修改，不能宣称抵抗能够同时修改 payload 与校验和的攻击者。

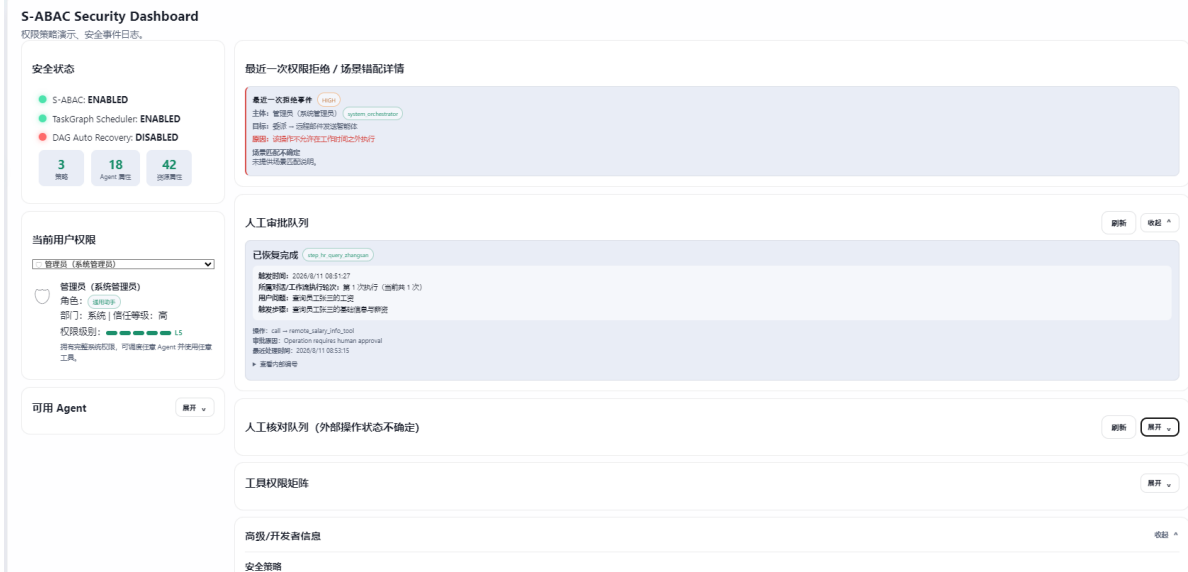


图 4-2 S-ABAC 权限治理成果展示

4.5 评测集与量化结果

权限治理评测定义 21 条机器可读用例，包括 12 条 API 决策、4 条端到端工作流和 5 条 Artifact、审批、清理及远程绕过用例。覆盖合法访问、工资越权、未知工具、岗位不匹配、邮件与会议审批、跨用户 Artifact、审批并发消费、远程 Agent 工具绕过和副作用恢复。

表 11 权限治理测试结果

测试组	结果	主要验证点
权限 API 决策矩阵	12/12	ALLOW、DENY、REVIEW_REQUIRED 与原因字段
主 Agent 决策结构与合同测试	113/113	意图、澄清、合同、TaskGraph 结构
权限治理核心测试	105/105	S-ABAC、审批、Artifact、Receipt、恢复
专题合并回归	252/253	唯一失败为前端静态资源缓存版本断

测试组	结果	主要验证点
		言




图 4-3 主 Agent 与权限治理回归结果

“105/105 权限治理核心测试通过”不能表述为所有权限场景已经生产验证。测试使用模拟用户、资源和本地持久化；合并回归也保留了 1 条 UI 缓存断言失败。诚实区分合同测试、固定评测集和线上泛化能力，是本课题评测方法的重要组成部分。

4.6 安全边界与生产化方向

当前是治理机制原型，已验证 S-ABAC、四道 PEP、Artifact 所有权、一次性审批、审计、校验和、幂等和恢复，但不宣称已实现真实统一身份认证、生产级密钥管理、AES-GCM 静态加密、Windows ACL 或公网生产部署。数据均为虚构员工和模拟业务数据。

生产化需接入真实 IAM/组织目录和短时委托凭证，将本地策略迁移到 OPA、Cedar 或企业权限平台，增加策略版本、仿真、冲突检测和灰度发布；为 Artifact 引入正式密钥管理与静态加密；对远程 Agent 与 MCP Server 建立身份认证、传输保护、来源签名和供应链治理。

4.7 本章小结

权限治理模块把“模型应该遵守”转化为“执行系统必须校验”。S-ABAC、四道 PEP、三态审批、Artifact Guard 和 Receipt 分别回答谁能做、能对什么做、何时需要人确认、能读到什么以及是否已经执行，从而形成可阻断、可恢复、可追溯的任务级治理闭环。

总体结论

本研究形成了面向数字员工复杂任务执行的总体技术框架，并在任务书要求的典型办公场景中完成原型与评测。四个模块之间的关键关系为：主 Agent 用 TaskProfile 和 RoutingDecision 决定“做什么、由谁做”；多 Agent 编排用 TaskGraph、Scheduler 和 Tool Resolver 决定“按什么顺序、调用什么能力”；Memory 与 Skill 决定“保留什么状态、哪些经验可以复用”；权限治理决定“是否允许、数据如何流转、执行后如何证明”。

相对同类通用框架，本项目不追求用一个模型或一种 Agent 对话模式包办全部问题，而是将开放语义判断与确定性合同、策略、持久化和副作用控制分工。原型已经达到不少于 10 个 Agent、30 个 MCP 工具的结构化要求，并形成分层评测证据。当前最值得继续投入的方向包括：统一在线语义评测与对照基线；让 Tool Resolver 从 audit 进入经过回归验证的 enforce 模式；为长期记忆补充真实对话提取基准，并扩充 Skill 的输入绑定变化、向后兼容 Schema、不同副作用等级和在线 LLM 反思样本；接入生产身份、外置策略中心、加密存储与分布式持久化。

附录 A 关键实现与证据索引

表 12 关键实现与证据索引

能力	主要实现或证据
TaskProfile 与意图识别	src/contracts/task_profile.py、 src/orchestrator/intent_recognition.py、 tests/intent_eval_cases.json
AgentCard 与路由	src/contracts/agent_card.py、 src/orchestrator/department_router.py、 src/contracts/routing_decision.py
计划可信化与 TaskGraph	src/orchestration/contract_planning.py、 plan_to_task_graph.py、scheduler.py
Artifact 数据面	src/orchestration/store.py、resolver.py、artifact_guard.py
30 个 Office MCP 工具	src/tools/office_mcp/server.py、 docs/office_mcp_prototype.md
18 个 Excel MCP 工具	src/tools/excel/server.py
上下文压缩	src/memory/compaction.py
长期记忆	src/memory/manager.py、models.py、consolidation.py
步骤/智能体 Skill	src/skills/agent_skill.py、execution_evidence.py、

能力	主要实现或证据
	reflection.py
S-ABAC 与执行闸门	src/security/policy.py、enforcement.py、tool_wrapper.py、remote_tool_gate.py
审批、回执与恢复	src/security/approval.py、src/orchestration/completion.py、recovery.py
权限治理评测	tests/evaluations/permission_governance_eval.json、docs/权限治理评测集.md